(19)国家知识产权局

(12)发明专利申请

(10)申请公布号 CN 121170422 A
(43)申请公布日 2025.12.19

(21)申请号 202511322200.3
(22)申请日 2025.09.16
(71)申请人 南京理工大学
地址 210014 江苏省南京市玄武区孝陵卫街道孝陵卫街200号
(72)发明人 郁奕辰 梅镇 时龙 王喆 李骏
(74)专利代理机构 重庆辉腾律师事务所 50215
专利代理师 皮燕
(51)Int.Cl.
G06V 10/764(2022.01)
G06V 10/77(2022.01)
G06V 10/774(2022.01)
G06V 10/80(2022.01)
G06V 10/82(2022.01)
G06T 7/00(2017.01)
G06N 3/0464(2023.01)
G06N 3/0895(2023.01)

权利要求书3页 说明书6页 附图3页

(54)发明名称

一种基于渐进式条件扩散模型的跨域工业缺陷分类方法

(57)摘要

本发明涉及工业缺陷分类技术领域,尤其是涉及一种基于渐进式条件扩散模型的跨域工业缺陷分类方法,包括扩散模型和分类模型。训练过程主要包含:将源域图像输入扩散模型,获取模型在不同时间步以及各个特征层的输出特征图,经过分类模型得到分类结果,过程中通过Grad-CAM方法得到梯度热力图,并通过一个特征融合网络得到强监督图像,同时利用像素均值消除方法对原始图像进行处理,生成弱监督图像,将两图像进行加权融合并随着训练渐进式调整权重,注入到扩散模型中,得到图像重建损失,与分类损失求和作为总损失;在目标域上冻结扩散模型,只使用目标域上的少量原图样本与弱监督图像对于分类模型进行微调。模型在跨域小样本场景下具有强大迁移泛化性能。

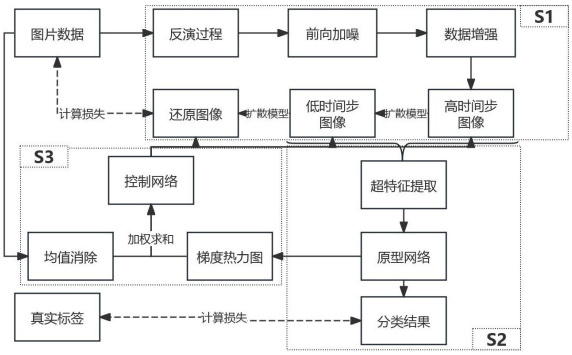

CN 121170422 A

1.一种基于渐进式条件扩散模型的跨域工业缺陷分类方法,包括扩散模型和分类模型,扩散模型使用稳定扩散模型进行图像重建,稳定扩散模型采用UNet网络作为主干,分类模型使用原型网络,其使用ResNet作为编码器,并基于欧式距离得到分类结果;训练过程中模型利用源域数据训练扩散模型和分类模型,迁移到目标域后冻结扩散模型并对分类模型进行微调,微调时将目标域样本输入扩散模型进行图像域迁移,利用迁移后的样本对分类模型进行训练;其特征在于,使用基于卷积神经网络的渐进式条件图像控制网络对于稳定扩散模型进行图像重建提供条件注入,对于扩散模型的具体训练过程包括以下步骤:

将源域的原始图像输入稳定扩散模型,获取扩散模型在不同时间步的特征图以及扩散模型的UNet网络中各个特征层输出的特征图;

将不同时间步的特征与各个特征层输出的特征分别拼接后,经过分类模型得到分类结果,并计算分类损失;

在通过分类模型的同时,通过Grad-CAM方法将拼接的特征映射为梯度热力图;

所有梯度热力图通过一个单层卷积层进行特征融合得到强监督图像;

利用像素均值消除方法对原始图像进行处理,生成弱监督图像;

使用余弦退火算法将强监督图像与弱监督图像进行加权融合得到条件图像;

将条件图像通过控制网络生成不同尺度的特征图,将得到的特征图作为残差注入到与其尺寸匹配的UNet网络的下采样层和瓶颈层中,控制扩散模型网络重建;

根据扩散模型重建结果计算损失,以进行训练。

2.根据权利要求1所述的一种基于渐进式条件扩散模型的跨域工业缺陷分类方法,其特征在于,使用余弦退火算法将强监督图像与弱监督图像进行加权融合得到条件图像,实现训练前期赋予强监督图像更大的权重,后期赋予弱监督图像更大的权重。

3.根据权利要求1所述的一种基于渐进式条件扩散模型的跨域工业缺陷分类方法,其特征在于,条件图像的融合表示为:

$$I_{\mathrm{mix}} = \alpha I_1 + (1-\alpha) I_2;$$

$$\alpha = 0.5 \times \left(1 + \cos\left(\frac{\pi \cdot k}{K}\right)\right);$$

其中,I_{mix}为条件图像;I_1为强监督图像;I_2为弱监督图像;α为退火因子;K为最大训练次数;k为当前训练次数。

4.根据权利要求1所述的一种基于渐进式条件扩散模型的跨域工业缺陷分类方法,其特征在于,扩散模型在不同时间步加噪后图像的计算包括:

$$x_t = \sqrt{\alpha_t} x_0 + \sqrt{1-\alpha_t} \epsilon_\theta(x_0, t);$$

其中,x_t为加噪后的图像,α_t预定义的时间步调度系数;x_0为原始图像,$\epsilon_\theta(x_0, t)$为扩散模型预测出的原始图像在时间步t上的噪声成分。

5.根据权利要求1所述的一种基于渐进式条件扩散模型的跨域工业缺陷分类方法,其特征在于,样本输入扩散模型进行图像增强的过程包括:

101、对图像x_0进行反向时序噪声预测,生成与扩散过程匹配的噪声分布,并使用与扩散模型去噪相反的反演噪声叠加方法,将噪声逐步注入图像,即:

$$x_{t+1}=\sqrt{\alpha_{t+1}}\,\hat{x}_0+\sqrt{(1-\alpha_{t+1})-\sigma_t^2}\,\epsilon_\theta(x_t,t)+\sigma_t\cdot z,\quad z\sim\mathcal{N}(0,I);$$

$$\sigma_t=\eta\cdot\sqrt{\left(1-\frac{\alpha_t}{\alpha_{t+1}}\right)\cdot\frac{1-\alpha_{t+1}}{1-\alpha_t}};$$

其中,x_{t+1}为时间步$t+1$加噪后的图像,α_{t+1}为随时间步变化的调度系数,η为预定义的超参数控制加噪程度,$\hat{x}_0$为预测出的原始图像,$\epsilon_\theta(x_t,t)$为扩散模型预测出的原始图像在时间步t上的噪声成分,$\mathcal{N}(0,I)$为标准高斯噪声,z为符合标准高斯噪声分布的随机数,σ_t为一个中间参数;

102、在反演加噪后的图像x_t上叠加高斯噪声,即:

$$x_t'=x_t+n;$$

取值,x_t'为中间噪声图像,n为高斯噪声;

103、将x_t'切割为多个图像块并进行随机重排;

104、通过扩散模型的反向去噪过程逐步生成增强图像x_0',即:

$$x_{t-1}'=\frac{1}{\sqrt{\alpha_{t-1}}}\left(x_t'-\frac{1-\alpha_t}{\sqrt{1-\alpha_t}}\epsilon_\theta(x_t',t)\right)+\sqrt{1-\alpha_{t-1}};$$

其中,$\epsilon_\theta(x_t',t)$为扩散模型预测出的中间噪声图像x_t'在时间步t上的噪声成分。

6.根据权利要求1所述的一种基于渐进式条件扩散模型的跨域工业缺陷分类方法,其特征在于,在目标域上,利用增强后的样本以及目标域样本对分类模型进行训练包括:冻结扩散模型与分类模型除了最后的分类层及最后三个残差块外的参数,仅训练分类层及最后三个残差块。

7.根据权利要求1或6所述的一种基于渐进式条件扩散模型的跨域工业缺陷分类方法,其特征在于,分类模型采用原型网络实现,即在分类模型中将样本划分为已知标签的支持集和待分类的查询集,通过计算查询集中样本与支持集中样本原型的特征距离得到分类结果,具体分类概率公式为:

$$f_\theta(c=\tilde{c}|x;S^{\text{set}})=\frac{\exp\left(-\left\|z_\theta(x)-P_{\tilde{c}}\right\|_2\right)}{\sum_{\tilde{c}'}\exp\left(-\left\|z_\theta(x)-P_{\tilde{c}'}\right\|_2\right)},x\in Q^{\text{set}};$$

其中,$f_\theta(c=\tilde{c}|x;S^{\text{set}})$为通过原型网络预测出的为特定类别的概率;$c$为实际缺陷类别,$\tilde{c}$为预测图像类别,$x$为从查询集中取出的输入样本的特征表示,$S^{\text{set}}$为支持样本集,$Q^{\text{set}}$为查询样本集;$z_\theta(\cdot)$表示特征提取网络;$P_{\tilde{c}}$表示对应类别原型的特征中心;$\|\cdot\|_2$表示二阶范数。

8.根据权利要求1所述的一种基于渐进式条件扩散模型的跨域工业缺陷分类方法,其特征在于,利用源域数据训练扩散模型时,将扩散模型多层多时间步的UNet输出特征输入分类网络进行分类,得到分类损失。

9.根据权利要求1所述的一种基于渐进式条件扩散模型的跨域工业缺陷分类方法,其特征在于,利用源域数据训练分类模型时,使用交叉熵损失将预测的类别概率转化为分类损失,并结合扩散模型的重建损失,共同作为分类模型的损失函数。

10.根据权利要求1所述的一种基于渐进式条件扩散模型的跨域工业缺陷分类方法,其特征在于,在目标域使用扩散模型时,将待处理图像的均值消除后的图像作为条件图像输入控制网络。

一种基于渐进式条件扩散模型的跨域工业缺陷分类方法

技术领域

[0001] 本发明涉及工业缺陷分类技术领域,尤其是涉及一种基于渐进式条件扩散模型的跨域工业缺陷分类方法。

背景技术

[0002] 随着工业4.0战略的深入实施以及智能制造的快速发展,工业缺陷分类技术在制造业、汽车工业、航空航天等关键领域的应用需求显著增加。在这些领域,高效准确的缺陷分类不仅能够提高生产效率,还能降低生产成本,保障产品质量。然而,实际工业生产场景中,缺陷类型的多样性和不可预测性对现有分类方法提出了严峻挑战。尤其在目标领域与源域数据存在显著分布差异的跨领域场景下,传统缺陷分类系统往往面临泛化性能不足的困境,导致在目标域上容易出现严重的准确度下降。

[0003] 当前主流方法通常依赖大规模数据来提升模型性能。然而,现有扩散模型大多在通用数据集上训练,在缺陷数据集上往往面临着缺陷重建效果差、无法还原低细粒度缺陷特征的问题,一些低细粒度缺陷往往会被噪声覆盖导致在重建时难以恢复分类所需特征。此外,传统分类模型在面对因生产线差异、材料变化或环境条件波动引起的数据分布偏移时,往往难以实现有效的领域自适应,导致分类性能显著下降。而在工业环境中,获取特定环境下的高质量标注缺陷数据成本高昂且周期冗长。因此,尽管近年来扩散模型在图像生成与风格迁移领域展现了强大的潜力,但在跨领域场景下仍存在关键瓶颈。

[0004] 在现有技术中,基于扩散模型的跨领域迁移方法虽能部分缓解数据稀缺问题,但在如何高效地利用网络特征进行分类与如何简化模型结构方面仍缺乏系统性设计,限制了其在工业缺陷分类任务中的实际应用价值。因此,需要一种能够兼顾数据生成质量、领域适应能力及小样本分类性能的创新方法。

发明内容

[0005] 为了能够兼顾数据生成质量、领域适应能力及小样本分类性能,以应对工业缺陷检测中的复杂需求,本发明提出一种基于渐进式条件扩散模型的跨域工业缺陷分类方法,包括扩散模型和分类模型,扩散模型使用稳定扩散模型进行图像重建,稳定扩散模型采用UNet网络作为主干,并添加基于卷积神经网络的条件图像控制网络对于图像重建提供条件注入,分类模型使用原型网络,其使用ResNet作为编码器,并基于欧式距离得到分类结果;训练过程中模型利用源域数据训练扩散模型和分类模型,迁移到目标域后冻结扩散模型并对分类模型进行微调,微调时将目标域样本输入扩散模型进行图像域迁移,利用迁移后的样本对分类模型进行训练;对于扩散模型的具体训练过程包括以下步骤:

[0006] 将源域的原始图像输入稳定扩散模型,获取扩散模型在不同时间步的特征图以及扩散模型的UNet网络中各个特征层输出的特征图;

[0007] 将不同时间步的特征与各个特征层输出的特征分别拼接后,经过分类模型得到分类结果,并计算分类损失;

[0008] 在通过分类模型的同时,通过Grad-CAM方法将拼接的特征映射为梯度热力图;

[0009] 所有梯度热力图通过一个基于卷积神经网络的特征融合网络融合得到强监督图像;

[0010] 利用像素均值消除方法对原始图像进行处理,生成弱监督图像;

[0011] 使用余弦退火算法将强监督图像与弱监督图像进行加权融合得到条件图像;

[0012] 将条件图像通过控制网络生成不同尺度的特征图,将得到的特征图作为残差注入到与其尺寸匹配的UNet网络的下采样层和瓶颈层中。

[0013] 本发明采用上述一种基于渐进式条件扩散模型的跨域工业缺陷分类方法,具备以下有益效果:

[0014] (1)通过单一扩散模型同时实现特征迁移、特征提取及图像生成,解决传统方法中多模块分离导致的模型结构复杂与一致性不足问题;

[0015] (2)综合利用扩散过程中不同时间步的多分辨率特征(高时间步的低分辨率粗粒度特征,低时间步的高分辨率细粒度特征)及UNet多层特征,使模型对于不同大小及细粒度的缺陷分别进行处理,通过特征拼接与残差注入增强跨领域缺陷表征的鲁棒性,更好地完成图像分类;

[0016] (3)结合课程学习的渐进式控制策略,采用强监督与弱监督信号的融合方法,解决了由于域迁移导致的强监督信号产生偏差的问题。同时,充分挖掘扩散模型在多分辨率、多时间步特征上的优势,对于UNet不同层数都能得到有效的缺陷位置指导,有效提升了模型在低细粒度缺陷图像重建方面的表现;

[0017] (4)通过扩散模型实现小样本图像迁移,通过反演变换重构目标域特征分布,结合高斯噪声注入、图像块随机化、图像重建等步骤,生成具有源域特征分布的,具有多样性、高可靠性的缺陷数据,显著提升分类模型的分类准确度。

附图说明

[0018] 图1为本发明一种基于渐进式条件扩散模型的跨域工业缺陷分类方法的整体框架图;

[0019] 图2为本发明工业分类方法步骤流程图;

[0020] 图3为本发明实施例的训练结果图。

具体实施方式

[0021] 下面将结合本发明实施例中的附图,对本发明实施例中的技术方案进行清楚、完整地描述,显然,所描述的实施例仅仅是本发明一部分实施例,而不是全部的实施例。基于本发明中的实施例,本领域普通技术人员在没有做出创造性劳动前提下所获得的所有其他实施例,都属于本发明保护的范围。

[0022] 本发明提出一种基于渐进式条件扩散模型的跨域工业缺陷分类方法,包括扩散模型和分类模型,扩散模型使用稳定扩散模型进行图像重建,稳定扩散模型采用UNet网络作为主干,分类模型使用原型网络,本实施例中采用ResNet18作为编码器,并基于欧式距离得到分类结果;训练过程中模型利用源域数据训练扩散模型和分类模型,迁移到目标域后冻结扩散模型并对分类模型进行微调,微调时将目标域样本输入扩散模型进行图像域迁移,

利用迁移后的样本对分类模型进行训练;对于扩散模型的具体训练过程包括以下步骤:

[0023] 将源域的原始图像输入稳定扩散模型,获取扩散模型在不同时间步的特征图以及扩散模型的UNet网络中各个特征层输出的特征图;

[0024] 将不同时间步的特征与各个特征层输出的特征分别拼接后,经过分类模型得到分类结果,并计算分类损失;

[0025] 在通过分类模型的同时,将拼接的特征映射为梯度热力图;

[0026] 所有梯度热力图通过一个单层卷积层进行特征融合得到强监督图像;

[0027] 利用像素均值消除方法对原始图像进行处理,生成弱监督图像;

[0028] 使用余弦退火算法将强监督图像与弱监督图像进行加权融合得到条件图像;

[0029] 将条件图像通过控制网络生成不同尺度的特征图,将得到的特征图作为残差注入到与其尺寸匹配的UNet网络的下采样层和瓶颈层中,控制扩散模型网络重建;

[0030] 根据扩散模型重建结果计算损失,以进行训练。

[0031] 如图1,本实施例源域训练过程分为步骤S1~S3,以下对本发明一种基于渐进式条件扩散模型的跨域工业缺陷分类方法的具体实施过程进行说明。

[0032] S1、利用源域数据对扩散模型进行训练。

[0033] 本实施例对源域缺陷图像进行归一化、尺寸标准化后,输入预训练的稳定扩散模型,本实施例中源域是指具有大量可用样本的缺陷分类领域,通过控制图像嵌入,引导模型生成重建图像。同时,使用低秩适应方式减小微调参数量。在模型训练时先冻结下采样块与中间块,并在交叉注意力层与输出层上构建低秩矩阵,通过对于低秩矩阵参数的训练在源域数据量相对较少的情况下,得到较好的稳定扩散模型。对于稳定扩散模型中的输出,根据重建图像与原图的均方误差(MSE)计算重建损失,公式为:

[0034] $$L_{\mathrm{Rec}}(\boldsymbol{y},\hat{\boldsymbol{y}})=\frac{1}{N}\sum_{i=1}^{N}(y_i-\hat{y}_i)^2$$

[0035] 其中,$L_{\mathrm{Rec}}(\boldsymbol{y},\hat{\boldsymbol{y}})$为重建图像与原图的均方误差,$\boldsymbol{y}$为样本的真实标签集合,$\hat{\boldsymbol{y}}$为样本的预测标签集合;$y_i$为样本i的真实标签,$\hat{y}_i$为样本i的预测标签,N为样本数量。

[0036] S2、利用源域数据对分类模型进行训练。

[0037] 利用扩散模型去噪过程中不同时间步及UNet网络的多层级特征,综合提取图像粗粒度和细粒度特征,通过不同时间步的不同细粒度,以及不同UNet层数的不同层次特征图,融合形成图像超特征表示,以提高分类模型与控制网络泛化能力。为了解决目标域样本量较小而可能导致的普通的基于全连接层的模型效果不佳的问题,此方法通过原型网络的方式,将样本划分为已知标签的支持集和待分类的查询集,通过计算查询集中样本与支持集中样本原型的特征距离得到分类结果,具体分类概率公式为:

[0038] $$f_\theta(c=\tilde{c}|x;S^{\mathrm{set}})=\frac{\exp\left(-\left\|z_\theta(x)-P_{\tilde{c}}\right\|_2\right)}{\sum_{\tilde{c}'}\exp\left(-\left\|z_\theta(x)-P_{\tilde{c}'}\right\|_2\right)},\qquad x\in Q^{\mathrm{set}}$$

[0039] 其中,c为实际缺陷类别,$\tilde{c}$为预测图像类别,x为从查询集中取出的输入样本的特征表示,S^{set}为支持样本集,Q^{set}为查询样本集,$f_\theta(y=\tilde{c}|x;S^{\mathrm{set}})$为通过原型网络预测出的为特定类别的概率,$z_\theta(\cdot)$表示特征提取网络(在本发明中为扩散模型与ResNet18网络),$P_{\tilde{c}}$表示对应类别原型的特征中心。

[0040] 使用交叉熵损失即可将类别概率转化为所需损失函数，结合分类损失$\mathcal{L}_{\mathrm{CE}}$与S1计算得到的重建损失$\mathcal{L}_{\mathrm{Rec}}$进行联合训练，总损失函数为：

[0041] $\mathcal{L}_{\mathrm{CE}}(f_{\theta}(\tilde{x}_u;S^{set}),\tilde{y}_u)=-\log(f_{\theta}(c=\tilde{c}|x;S^{\mathrm{set}}),\tilde{y}_u)$

[0042] $\mathcal{L}_{\mathrm{total}}=\mathcal{L}_{\mathrm{CE}}+\lambda\mathcal{L}_{\mathrm{Rec}}$

[0043] 其中，$\mathcal{L}_{\mathrm{total}}$为分类模型的损失函数；$\mathcal{L}_{\mathrm{CE}}(f_{\theta}(\tilde{x}_u;S^{set}),\tilde{y}_u)$为根据预测概率与交叉熵损失得到的综合分类损失函数，$f_{\theta}(\tilde{x}_u;S^{set})$表示根据输入数据$\tilde{x}_u$的到的分类标签，$\tilde{y}_u$为输入数据$\tilde{x}_u$的真实分类标签；$\lambda$为超参数平衡两个损失函数。

[0044] S3、渐进式条件图像控制图像重建。

[0045] 为解决扩散模型对于低细粒度缺陷重建上的不足，本发明引入条件图像进行指导。条件图像经过基于卷积神经网络的控制网络后在不同层级生成多张与扩散模型UNet不同分辨率特征相对应的特征图。每一张特征图在空间分辨率上与扩散模型对应层(下采样层或瓶颈层)的输出严格匹配，并经过零卷积(zero convolution)处理后，以残差的方式注入到该层输出中。具体来说，将对应大小的特征图与对应的下采样层或者瓶颈层的输出的尺寸相同的特征图相加，作为下一层输入，以辅助缺陷区域的有效重建。在源域训练时，将S2中多层、多时间步图像在分类模型最后一个卷积层生成的多张梯度热力图，经过尺度融合卷积网络后恢复为三通道特征图。在实际使用过程中，由于分类模型使用原型网络，为了正确计算梯度，对于支持与查询图像都使用基于支持样本的特征计算出的原型作为基准，使用样本到真实标签原型距离值的相反数作为梯度计算依据。生成的梯度热力图作为条件图像的第一部分。

[0046] 此外，将每张图像的每个像素与该图整体像素均值做差，即可得到均值消除后的图像，这一图像作为条件图像的第二部分。

[0047] 基于梯度热力图的图像由于经过分类网络指导，且依据多层多时间步联合生成，具有更强的指导作用与更大的可信度，因此可作为强监督图像。然而，由于跨域后分类模型的准确度会受到影响，并进而影响基于梯度热力图的条件图像，因此，为提升方法在目标域上的迁移效果，防止分类模型受到跨域效果影响，此方法使用课程学习模式，将基于均值消除的图像作为弱监督图像也送入控制网络中。

[0048] 为了得到更好地效果，此方法在训练初期给予强监督图像较大的权重，而在后期则以不受到分类模型影响的均值消除图像作为主要指导图像。权重调整使用余弦退火方法逐步减小弱监督图像权重，公式为：

[0049] $I_{\mathrm{mix}}=\alpha I_1+(1-\alpha)I_2$

[0050] $\alpha=0.5\times\left(1+\cos\left(\frac{\pi\cdot k}{K}\right)\right)$

[0051] 其中，I_{mix}为条件图像；I_1为强监督图像；I_2为弱监督图像；α为退火因子；K为最大训练次数；k为当前训练次数。

[0052] 为了防止在模型训练初期，预训练权重受到破坏，该方法逐步增大控制图像的控制强度以实现较好的控制与重建效果。

[0053] 特别地，在目标域上，则只使用均值消除后的图像作为条件图像输入控制网络。

[0054] 在模型实际部署过程中，通过小样本目标域数据对于模型进行微调以达到更好地

分类效果。具体来说,微调时冻结扩散模型权重,对目标域图像进行增强以逐步将目标域与源域进行对齐,具体过程为:

[0055] 1、反演加噪:基于冻结的扩散模型噪声预测网络ϵ_θ,对目标域图像x_0进行反向时序噪声预测,生成与扩散过程匹配的噪声分布。通过以下公式实现加噪:

[0056] $$x_{t+1} = \sqrt{\alpha_{t+1}}\,\hat{x}_0 + \sqrt{(1-\alpha_{t+1}) - \sigma_t^2}\,\epsilon_\theta(x_t, t) + \sigma_t \cdot z, \quad z \sim \mathcal{N}(0, I);$$

[0057] $$\sigma_t = \eta \cdot \sqrt{\left(1 - \frac{\alpha_t}{\alpha_{t+1}}\right) \cdot \frac{1-\alpha_{t+1}}{1-\alpha_t}}$$

[0058] 其中,x_{t+1}为时间步$t+1$加噪后的图像,α_{t+1}为随时间步变化的调度系数,本领域利用扩散模型根据PNDM采样调度器得到的调度系数;η为预定义的超参数控制加噪程度,$\hat{x}_0$为预测出的原始图像,$\epsilon_\theta(x_t, t)$为扩散模型预测出的t时间步图像的噪声成分,$\mathcal{N}(0, I)$为标准高斯噪声,z为符合标准高斯噪声分布的随机数,σ_t为一个中间参数;

[0059] 2、噪声增强:在反演加噪后的图像x_t上叠加高斯噪声$n \sim \mathcal{N}(0, \sigma^2\mathbf{I})$,生成中间噪声图像$x_t' = x_t + n$,以进一步增加数据多样性;

[0060] 3、图像块随机化:将x_t'切割为多个图像块并进行随机重排,打破局部空间关联性,同时对于样本量进行扩充;

[0061] 4、渐进式去噪生成:以随机化后的图像为初始状态,通过扩散模型的反向去噪过程逐步生成目标域增强图像x_0'公式为:

[0062] $$x_{t-1}' = \frac{1}{\sqrt{\alpha_{t-1}}}\left(x_t' - \frac{1-\alpha_t}{\sqrt{1-\alpha_t}}\epsilon_\theta(x_t', t)\right) + \sqrt{1-\alpha_{t-1}}$$

[0063] 其中,$z \sim N(0, \mathbf{I})$为期望为0、方差为单位矩阵的随机噪声,$\epsilon_\theta(x_t', t)$为模型预测出的图像噪声,α_t与α_{t-1}为根据PNDM采样调度器得到的调度系数。最终生成的图像与源域数据分布对齐,且包含目标域特征。

[0064] 生成过程中的特征图,保持与源域一致的多层数,多时间步特征输入策略,对分类模型进行轻量化微调。冻结除分类层及最后三个残差块外的参数,抑制过拟合并提升跨域泛化能力。

[0065] 作为一种可选实施方式,本实施例给出一种在工业上部署本发明的具体实施方式,包括源域训练和目标域微调两个部分,如图2,具体包括以下步骤:

[0066] 101、源域训练时,将样本图像作为输入,使用扩散模型生成的不同时间步的图像与扩散模型不同层数的特征进行拼接,将拼接后的数据输入原型网络得到分类输出;

[0067] 102、根据步骤101得到不同时间步的图像与扩散模型不同层数拼接得到的特征图,获取前述特征图的分类梯度热力图;

[0068] 103、获取样本图像的均值消除图,即计算样本图像的平均像素值,利用样本图像各像素的像素值减去平均像素值得到均值消除图;

[0069] 104、根据训练步数计算权重,并对均值消除图和热力图进行加权融合;

[0070] 105、利用扩散模型生成图像,使用低秩矩阵微调稳定扩散模型,训练次数加一,然后判断稳定扩散模型是否收敛,若收敛则完成源域训练,否则返回步骤101;

[0071] 201、目标域微调时,冻结稳定扩散模型的网络参数,输入目标域数据经过稳定扩散模型进行反演-加噪-生成过程得到生成图像;

[0072] 202、将生成图像作为目标域数据的一部分,对分类模型进行微调,完成微调后得到最终的分类模型,该模型可以在目标域进行较准确缺陷分类。

[0073] 本实施例结合仿真结果来阐述本发明所提方案的性能,仿真条件如下:基于PyTorch框架在NVIDIA GeForce RTX 4090 GPU的计算机上进行。扩散模型使用Stable Diffusion v1-5预训练模型作为参数初始化开始训练;将Severstal作为源域数据集,NEU作为目标域数据集。使用ResNet18作为分类模型框架;先将原图经过10步反演变换后,添加10个时间步的高斯噪声,之后将图片切割为4块,通过块随机化随机重排后进行20个时间步的反向去噪图像生成。在生成过程中,分别使用第1,10,20时间步分别对应的UNet的上采样块中最后两残差块的末层卷积神经网络层作为特征图像输入分类模型。图3给出本发明与现有技术其他方法的小样本缺陷分类方法进行比较,本发明准确度明显高于其他现有技术。

[0074] 因此,本发明采用上述一种基于渐进式条件扩散模型的跨域工业缺陷分类方法,有效解决了在工业缺陷任务中,训练数据与目标数据分布不同、模型泛化能力不足、目标域有标签样本较少和难以通过少量有标签样本高效进行样本生成等问题,提供了一种高效且准确的工业缺陷分类方法,能够提高工业缺陷分类的准确性和鲁棒性,适用于各类智能制造和工业缺陷分类场景。

[0075] 尽管已经示出和描述了本发明的实施例,对于本领域的普通技术人员而言,可以理解在不脱离本发明的原理和精神的情况下可以对这些实施例进行多种变化、修改、替换和变型,本发明的范围由所附权利要求及其等同物限定。

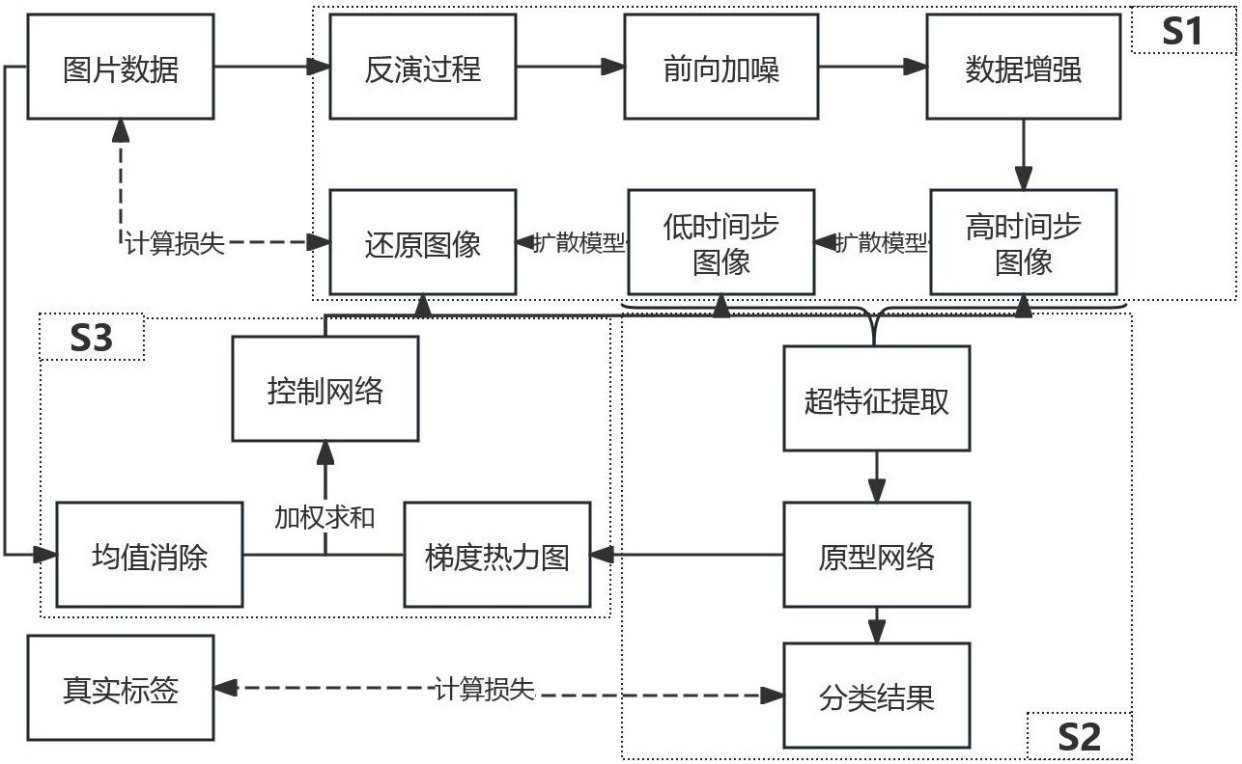
S1
图片数据
反演过程
前向加噪
数据增强
计算损失
还原图像
扩散模型
低时间步图像
扩散模型
高时间步图像
S3
控制网络
超特征提取
加权求和
均值消除
梯度热力图
原型网络
真实标签
计算损失
分类结果
S2

图 1

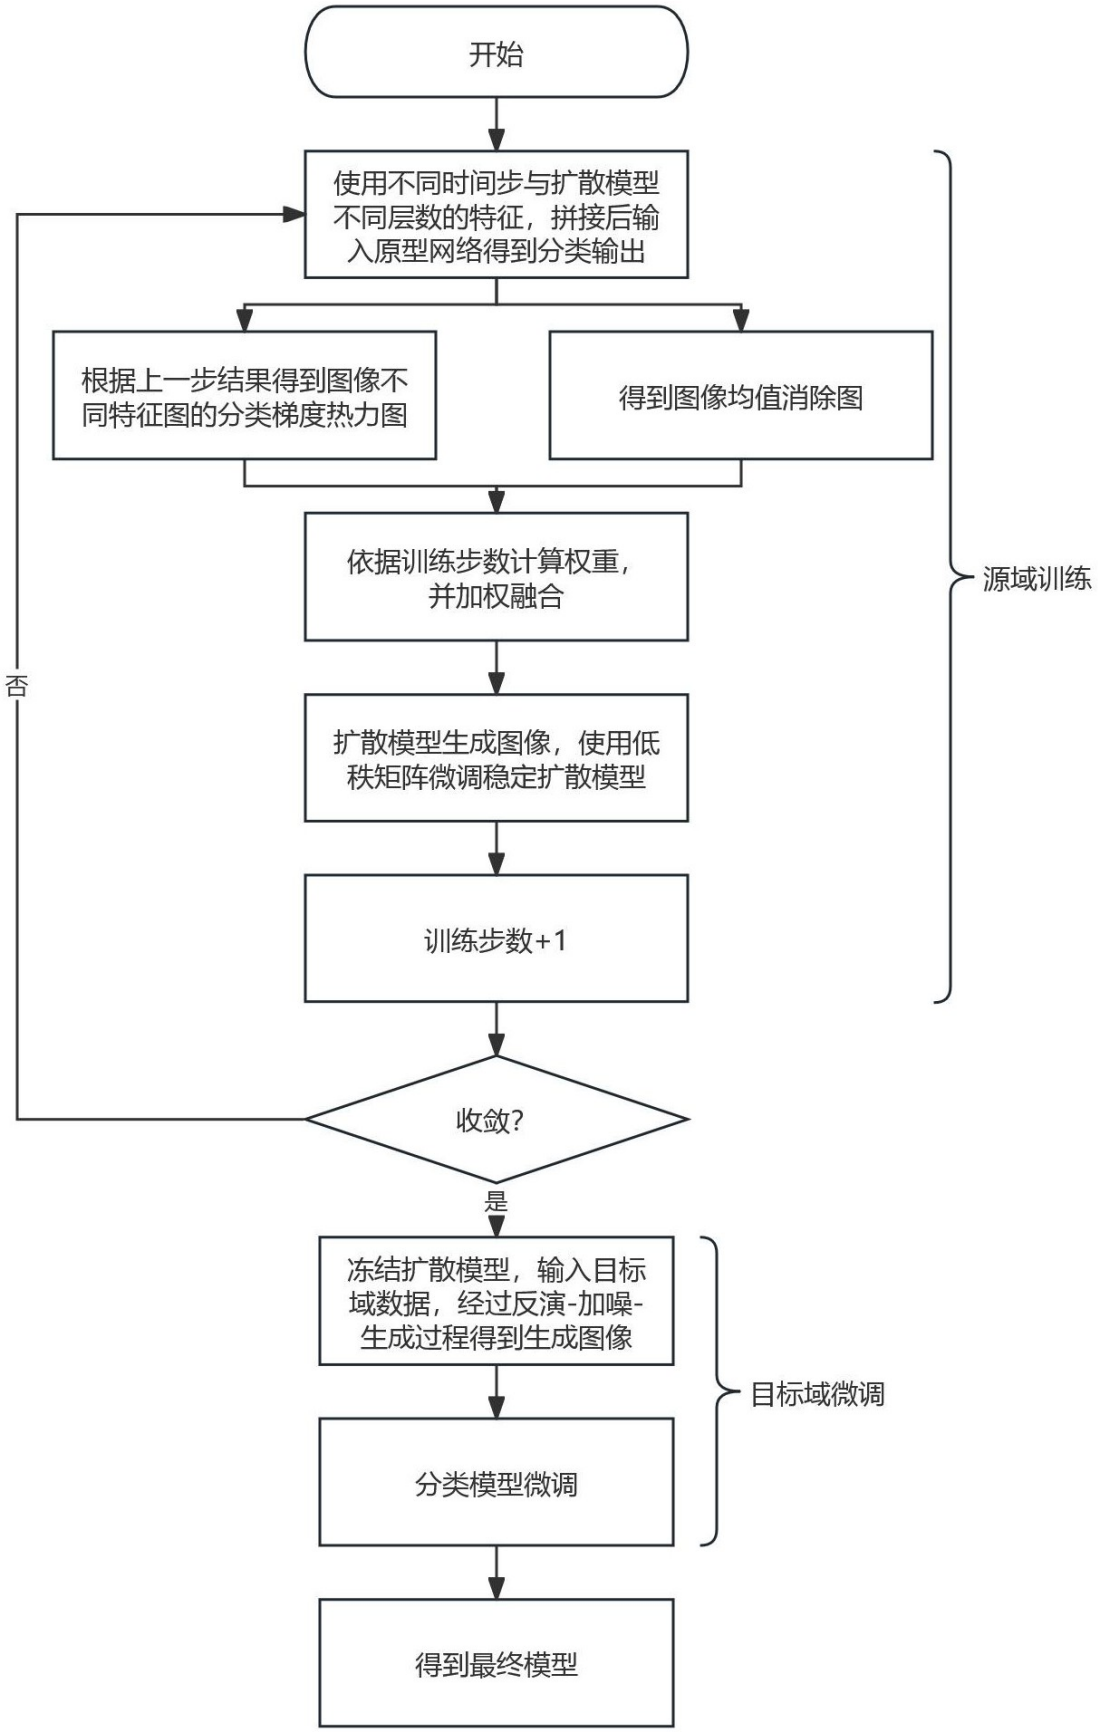
开始
使用不同时间步与扩散模型不同层数的特征，拼接后输入原型网络得到分类输出
根据上一步结果得到图像不同特征图的分类梯度热力图
得到图像均值消除图
依据训练步数计算权重，并加权融合
扩散模型生成图像，使用低秩矩阵微调稳定扩散模型
训练步数+1
源域训练
收敛?
否
是
冻结扩散模型，输入目标域数据，经过反演-加噪-生成过程得到生成图像
分类模型微调
目标域微调
得到最终模型

图 2

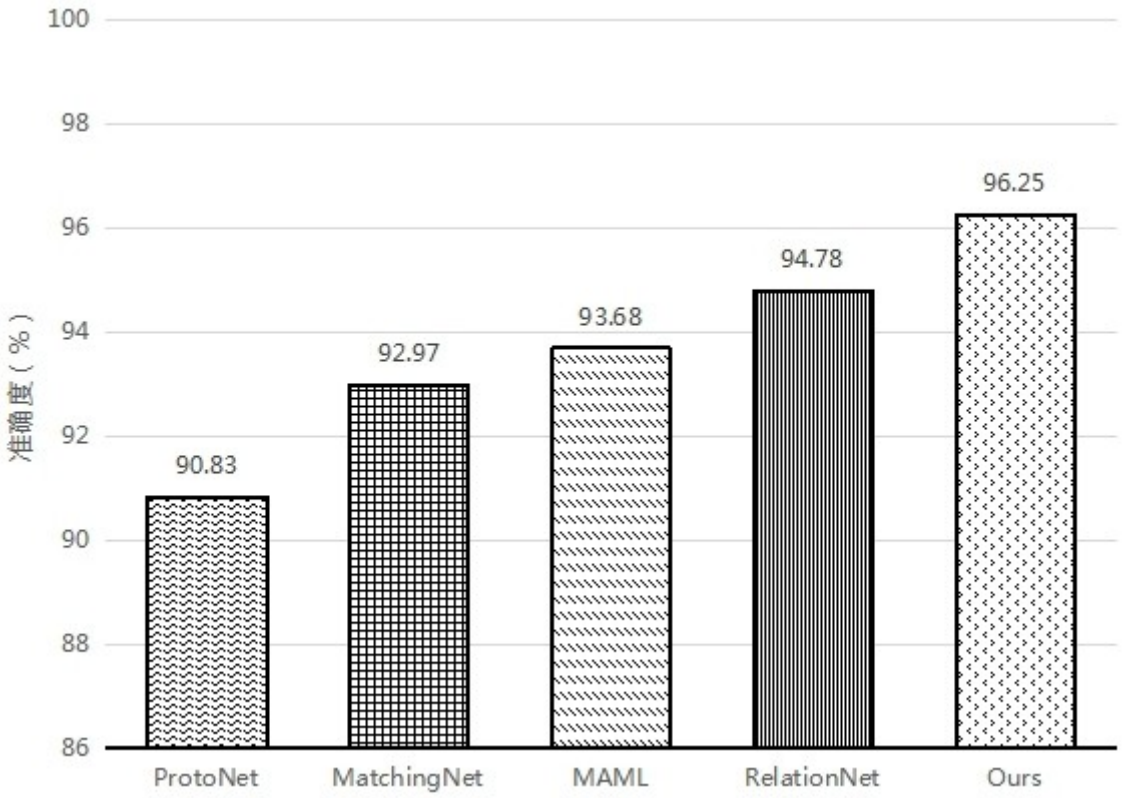
100
98
96
94
92
90
88
86
准确度（%）
90.83
92.97
93.68
94.78
96.25
ProtoNet
MatchingNet
MAML
RelationNet
Ours

图 3